

深度学习

卷积神经网络 (1)

谁看到了真实的世界？

HUMAN VISION



BIRD VISION




谁看到了真实的世界？

HUMAN VISION



SNAKE VISION

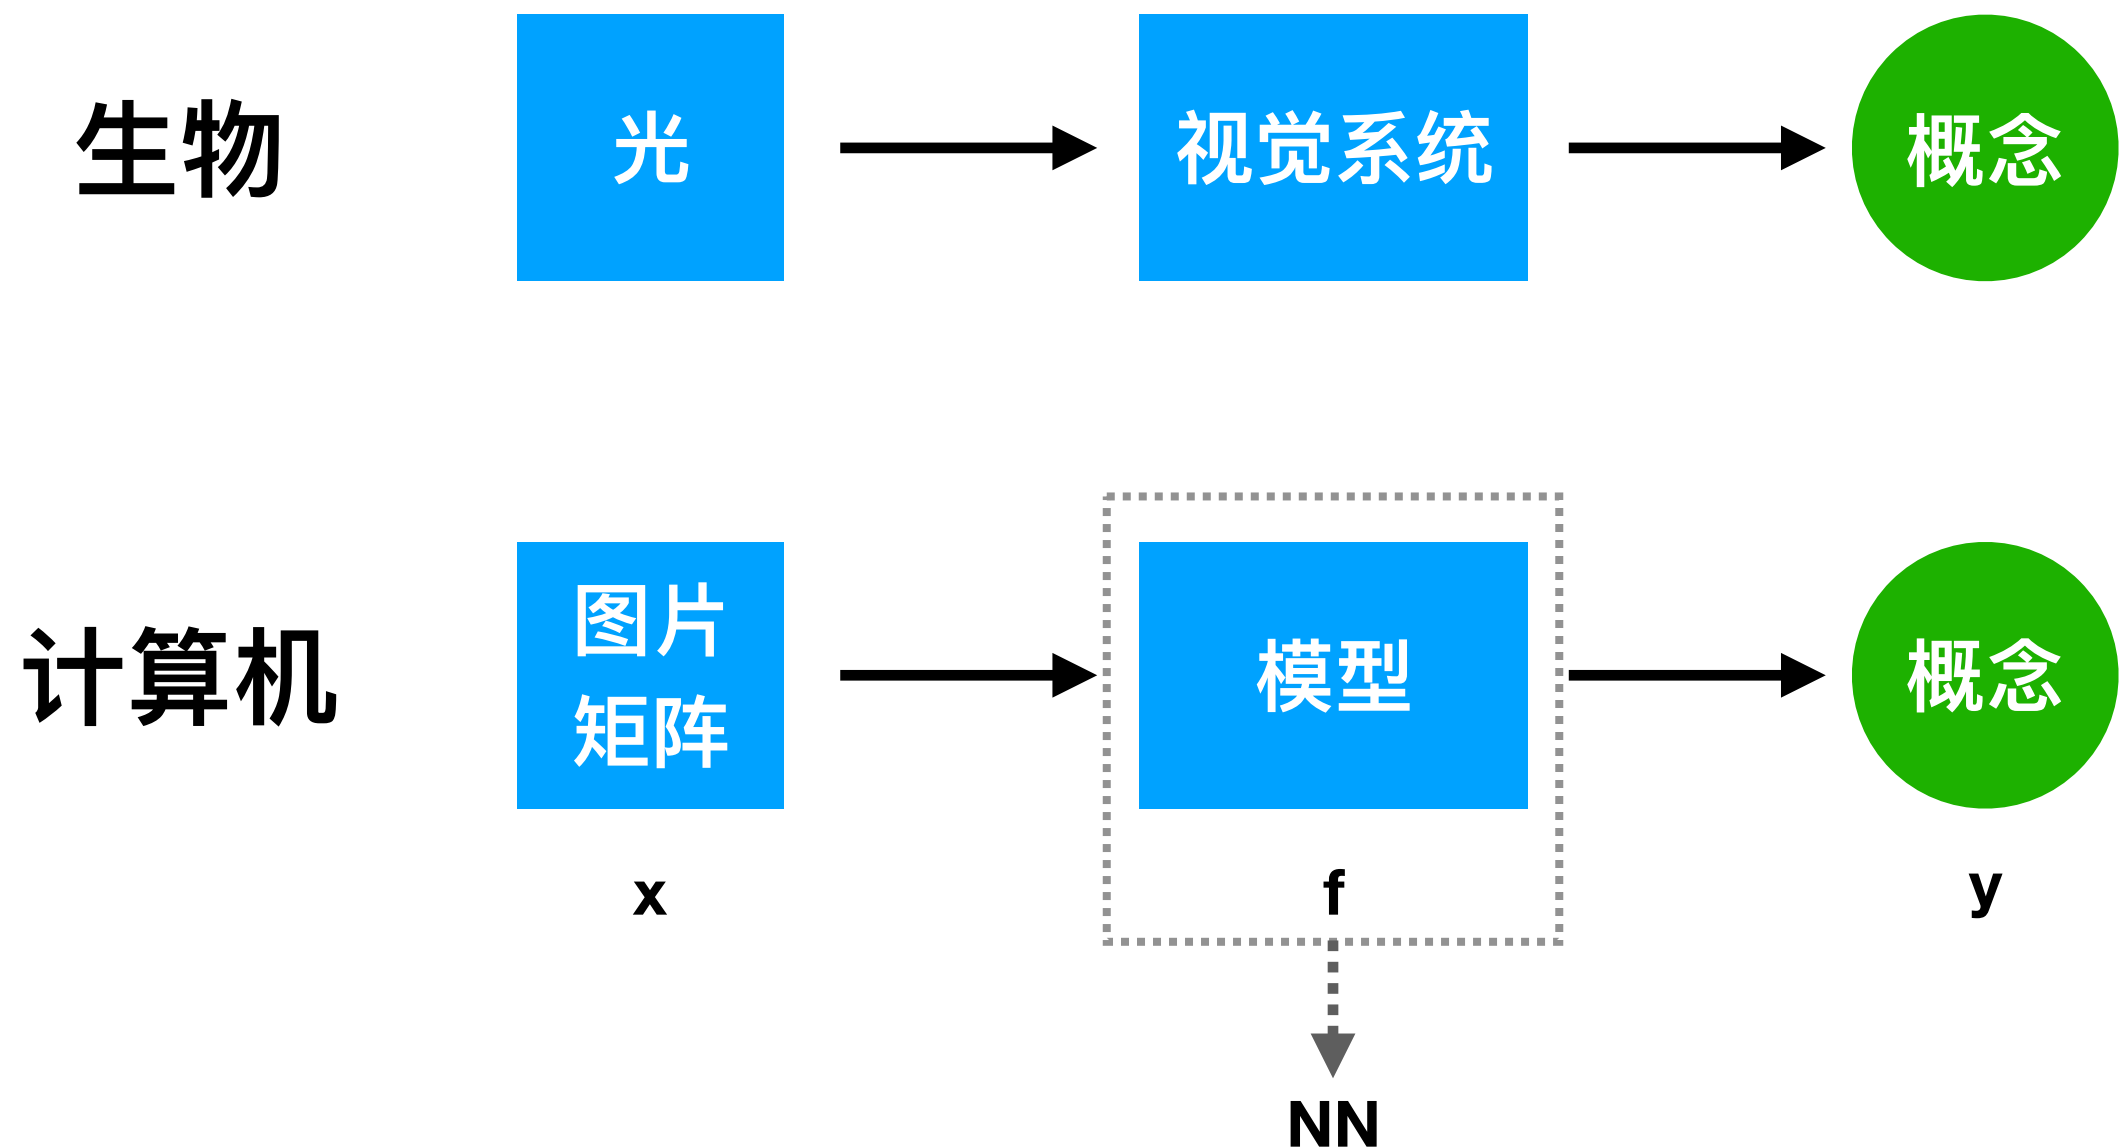


视觉的本质




视觉本质上是对外界刺激抽象出一个概念的过程。
我们所看到的世界是主观的世界，不是世界的本来面目。

计算机的视觉系统



视觉与机器视觉



人的视觉


0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0
0	0	0	0	1	12	0	11	39	137	37	0	152	147	84	0	0	0	0	0
0	0	1	0	0	0	41	160	250	255	235	162	255	238	206	11	13	0	0	0
0	0	0	16	9	9	150	251	45	21	184	159	154	255	233	40	0	0	0	0
10	0	0	0	0	0	145	146	3	10	0	11	124	253	255	107	0	0	0	0
0	0	3	0	4	15	236	216	0	0	38	109	247	240	169	0	11	0	0	0
1	0	2	0	0	0	253	253	23	62	224	241	255	164	0	5	0	0	0	0
6	0	0	4	0	3	252	250	228	255	255	234	112	28	0	2	17	0	0	0
0	2	1	4	0	21	255	253	251	255	172	31	8	0	1	0	0	0	0	0
0	0	4	0	163	225	251	255	229	120	0	0	0	0	0	11	0	0	0	0
0	0	21	162	255	255	254	255	126	6	0	10	14	6	0	0	9	0	0	0
3	79	242	255	141	66	255	245	189	7	8	0	0	5	0	0	0	0	0	0
26	221	237	98	0	67	251	255	144	0	8	0	0	7	0	0	11	0	0	0
125	255	141	0	87	244	255	208	3	0	0	13	0	1	0	1	0	0	0	0
145	248	228	116	235	255	141	34	0	11	0	1	0	0	0	1	3	0	0	0
85	237	253	246	255	210	21	1	0	1	0	0	6	2	4	0	0	0	0	0
6	23	112	157	114	32	0	0	0	0	2	0	8	0	7	0	0	0	0	0
0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0	0

计算机

图片通道





灰度图像



图片矩阵

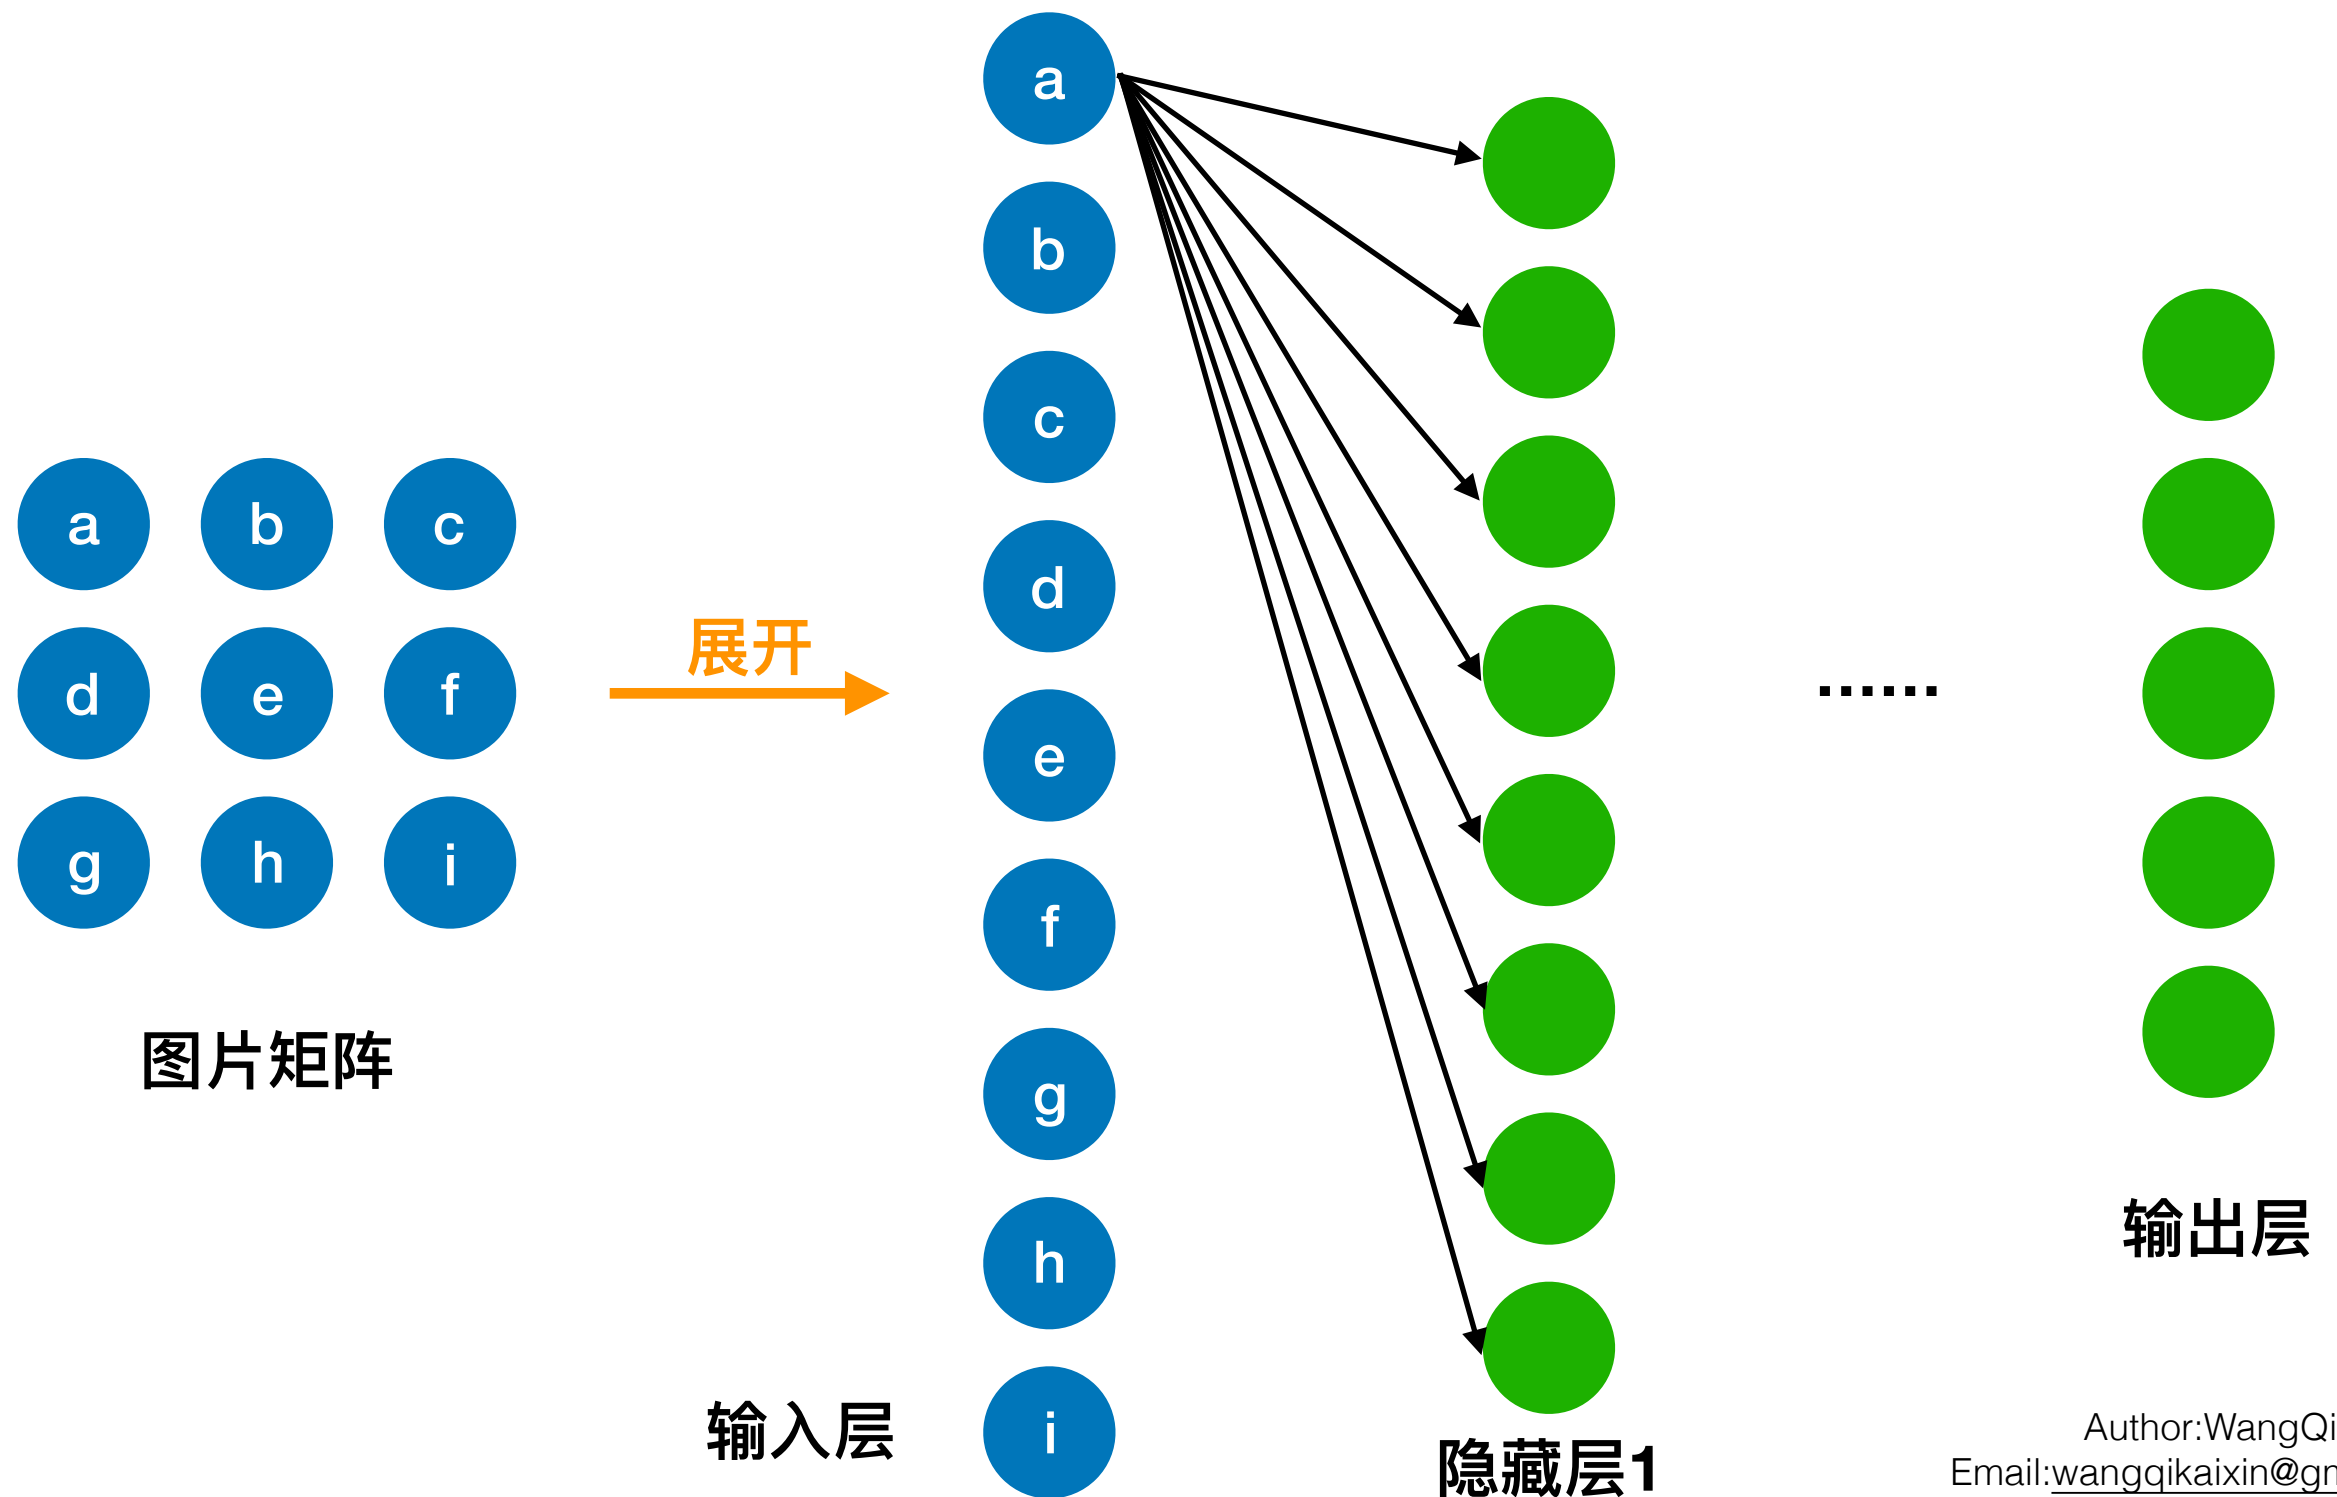


RGB图像

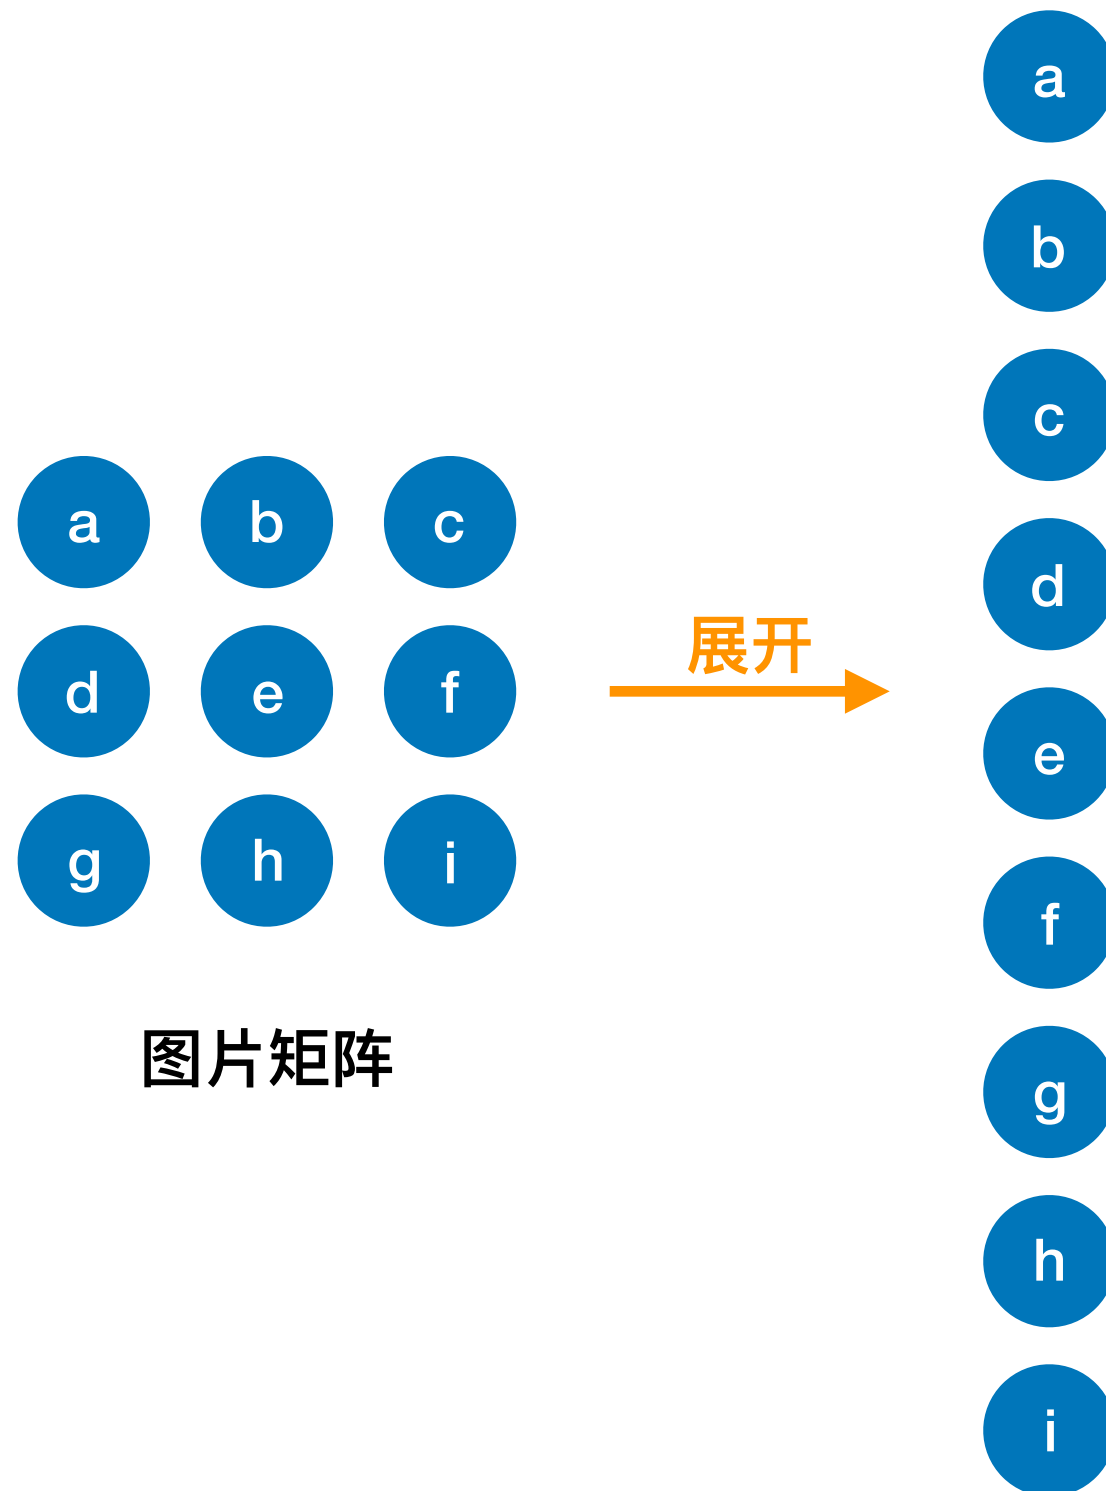


图片矩阵

使用普通ANN实现CV



使用普通ANN实现CV的问题




1. 2维矩阵展开丢失了二维信息
2. 输入层与隐藏层全连接带来了维度灾难问题

卷积神经网络

卷积神经网络(Convolutional Neural Network, CNN)是一种经典的前馈神经网络，主要受生物学中的**感受野(receptive field)**的概念提出。感受野在生物体中广泛存在，一个感受野连接多个感受器细胞，这些感受器细胞共同决定了感受野是否兴奋。通过感受野的机制，生物体传入的信号数量会大大降低，同时也能很好的对输入信号进行特征提取。卷积神经网络有两大工具来降低参数数目：卷积与池化。

感受器与感受野



5*5图片


局部感知：图像的局部联系紧密，局部像素可以作为整体的一个特征。

局部连接：具有紧密联系的局部区域与一个神经元相连。没有紧密联系的部分无须相连。



利用了2维信息，降低了连接数量。

感受器与感受野

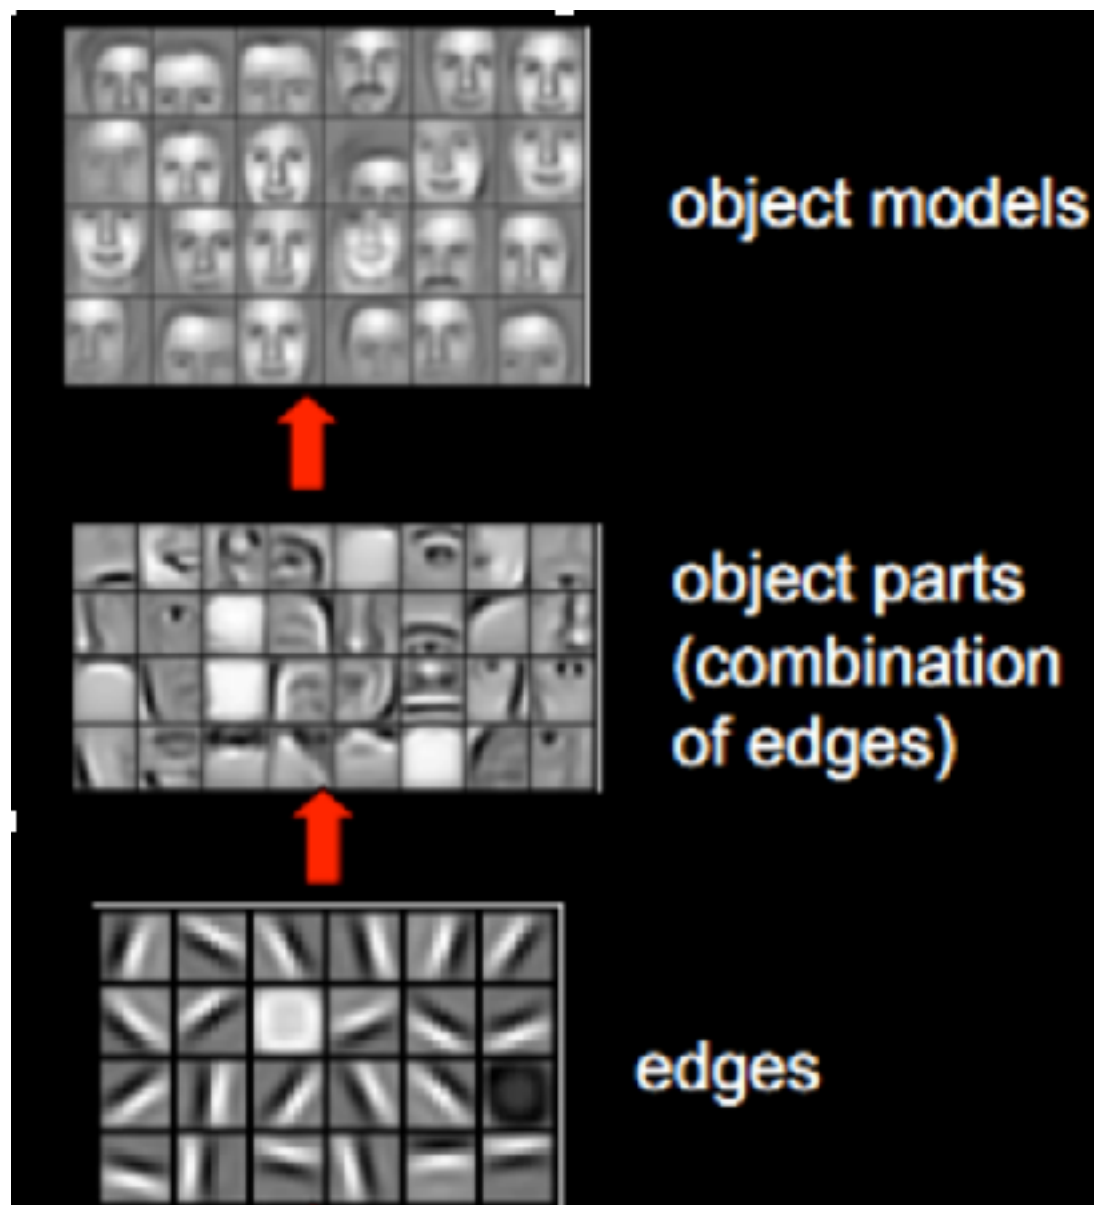


5*5图片

感受野感知到的信息是什么？

Hubel和Wiesel在1962年通过实验发现：大脑中的一些特别的神经细胞只会对特定方向的边缘做出反应。

感受器与感受野



“边”的特点：

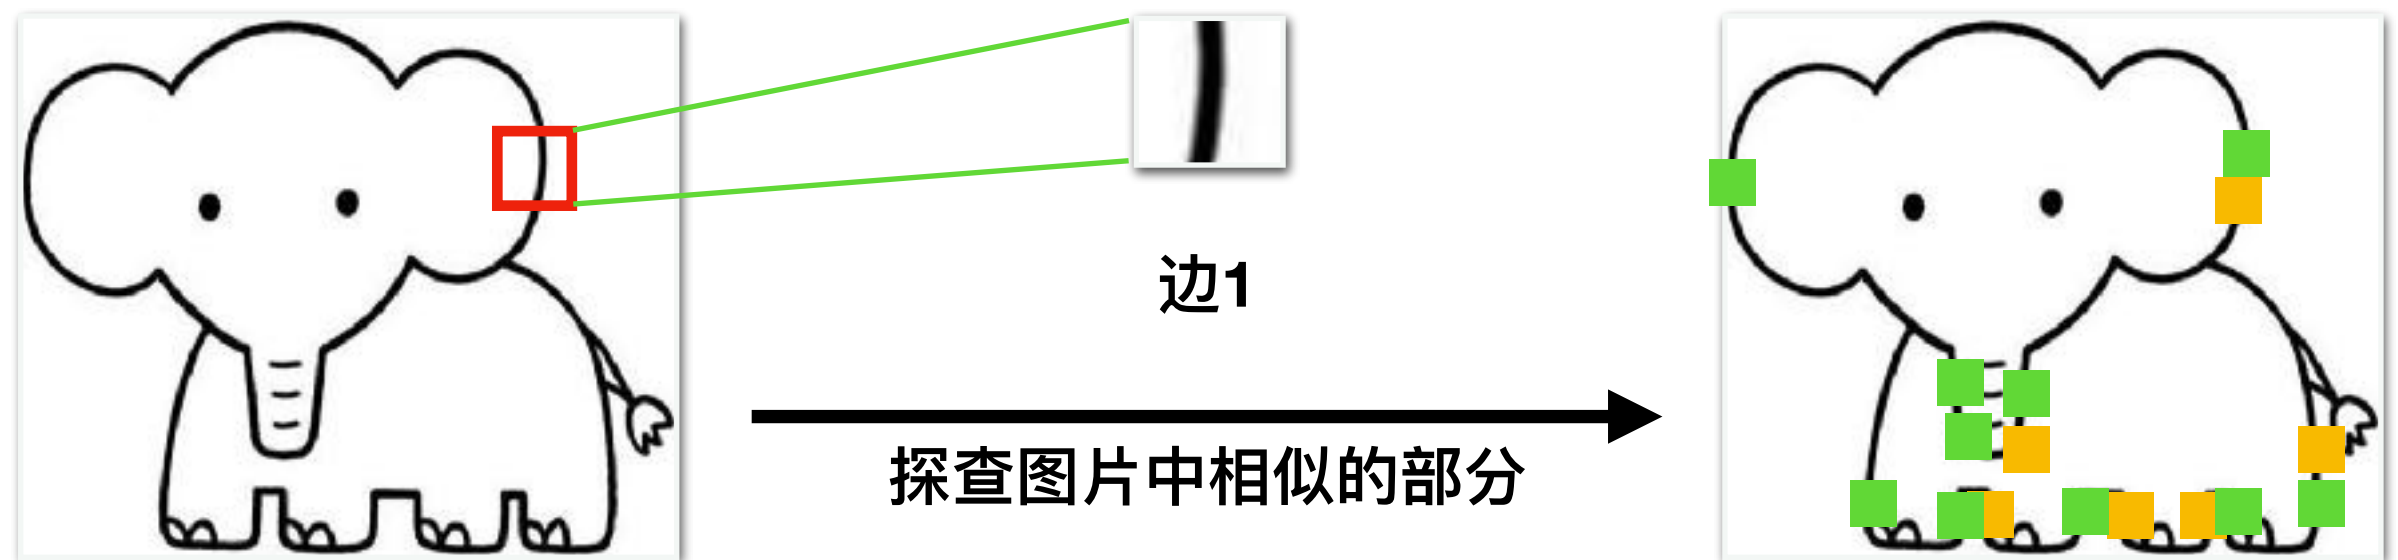
1. 每种“边”都是不同的。即每种“边”可以看作一种特征。
2. 有限数量的边可以构成无限多的图片。

规律：所有图片均可以通过一定数量的“边”组合得到。

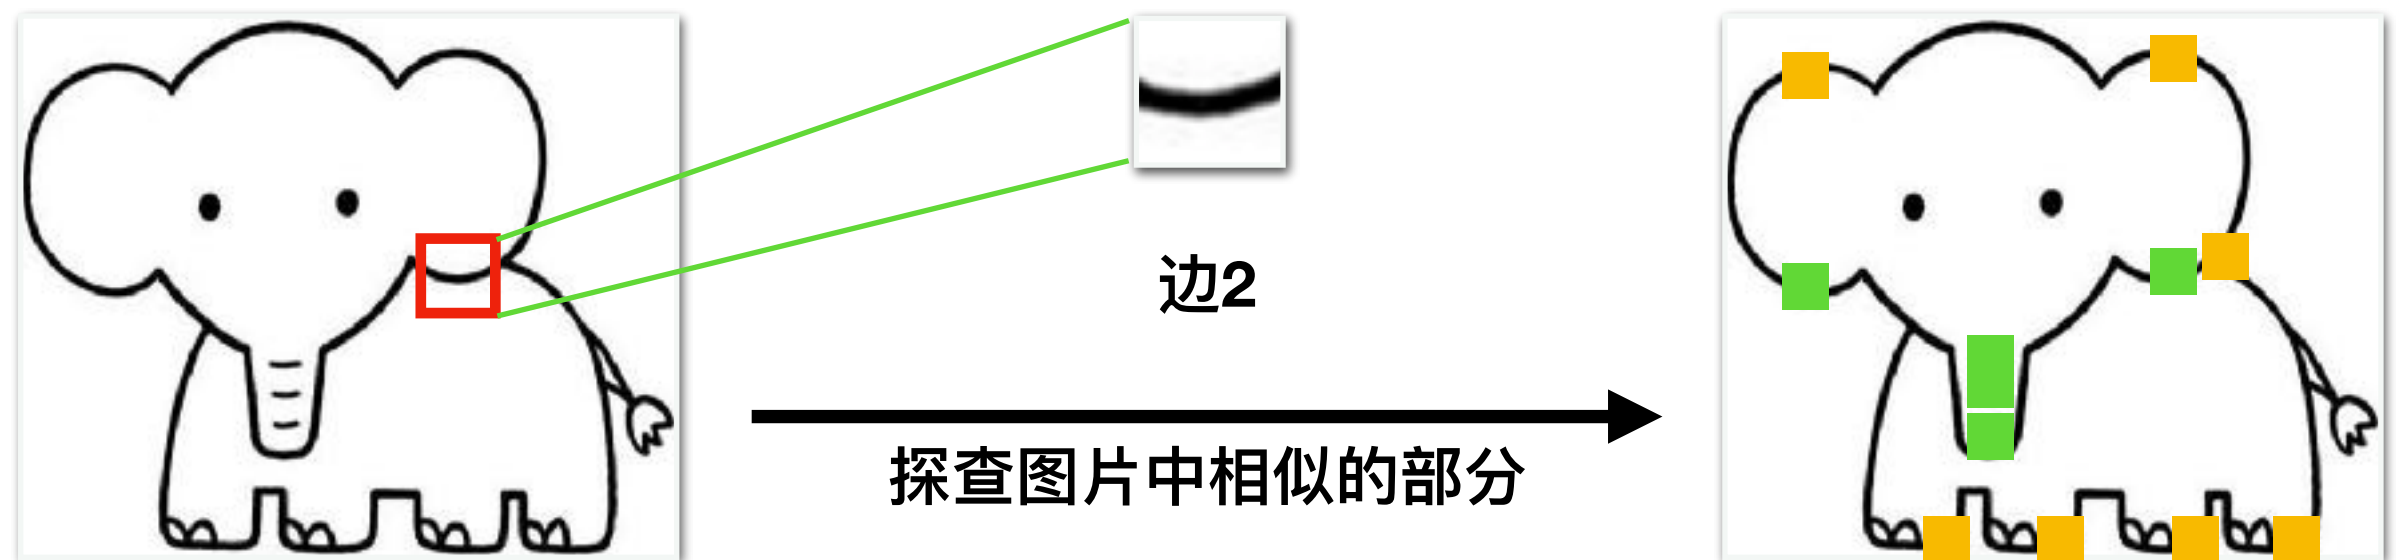
使用“边”构成各种人脸

思考：假如构成图像的“边”已知，如何使用这些“边”描述现有图像？

查找“边”在图像中的位置



查找“边”在图像中的位置



思考：人通过观察可以找到与“边”相似的部分，计算机该如何查找呢？

“边”矩阵




边1



0	0	100	0	0
0	0	100	0	0
0	0	100	0	0
0	0	90	0	0
0	20	70	0	0

边1对应的矩阵

子图1矩阵



图片



子图1



0	0	90	0	0
0	0	110	0	0
0	0	100	0	0
0	0	90	0	0
0	40	80	0	0

子图1对应的矩阵

求值

0	0	100	0	0
0	0	100	0	0
0	0	100	0	0
0	0	90	0	0
0	20	70	0	0

边1对应的矩阵


*

0	0	90	0	0
0	0	110	0	0
0	0	100	0	0
0	0	90	0	0
0	40	80	0	0

子图1对应的矩阵

$$y_1 = 100 * 90 + 100 * 110 + 100 * 100 + 90 * 90 + 20 * 40 + 70 * 80 = 44500$$

子图2矩阵



图片



子图2



0	0	0	0	0
0	0	30	0	0
80	80	100	80	70
20	0	0	0	10
0	0	0	0	0

子图2对应的矩阵

求值

0	0	100	0	0
0	0	100	0	0
0	0	100	0	0
0	0	90	0	0
0	20	70	0	0

边1对应的矩阵

*

0	0	0	0	0
0	0	30	0	0
80	80	100	80	70
20	0	0	0	10
0	0	0	0	0

子图2对应的矩阵

$$y_2 = 100 * 30 + 100 * 100 = 13000$$

两次求值对比

0	0	100	0	0
0	0	100	0	0
0	0	100	0	0
0	0	90	0	0
0	20	70	0	0



边1对应的矩阵

0	0	90	0	0
0	0	110	0	0
0	0	100	0	0
0	0	90	0	0
0	40	80	0	0



子图1对应的矩阵

0	0	0	0	0
0	0	30	0	0
80	80	100	80	70
20	0	0	0	10
0	0	0	0	0



子图2对应的矩阵

$$y_1 = 100 * 90 + 100 * 110 + 100 * 100 + 90 * 90 + 20 * 40 + 70 * 80 = 44500$$

$$y_2 = 100 * 30 + 100 * 100 = 13000$$

两次求值对比

0	0	100	0	0
0	0	100	0	0
0	0	100	0	0
0	0	90	0	0
0	20	70	0	0



边1对应的矩阵

0	0	90	0	0
0	0	110	0	0
0	0	100	0	0
0	0	90	0	0
0	40	80	0	0



子图1对应的矩阵

0	0	0	0	0
0	0	30	0	0
80	80	100	80	70
20	0	0	0	10
0	0	0	0	0



子图2对应的矩阵

与“边”接近的“子图”，对应元素乘积的和较大，反之较小。

**思考：只有与“边”相近的子图，对应
元素乘积和才会较大吗？**

卷积

1 _{x1}	1 _{x0}	1 _{x1}	0	0
0 _{x0}	1 _{x1}	1 _{x0}	1	0
0 _{x1}	0 _{x0}	1 _{x1}	1	1
0	0	1	1	0
0	1	1	0	0

Image

4		

Convolved
Feature

卷积隐含的原则是：输入（此处是图像）的一部分的统计特性与其他部分是一样的。



我们把3*3的“边”矩阵叫做卷积核(Convolution kernel)。右边的图是与卷积核运算的结果，我们把它叫做特征分布图，简称特征图(Feature map)。特征图反映了某个特征在某个输入（此处是图片）上的激活值。

思考：卷积一定是逐步滑动吗？

将“边”与所有可能的子图运算，就是卷积的过程。

注意：上面，为了便于理解，我们使用了统计得到的卷积核，实际中我们通过训练获得卷积核。

特征图




0	10	5	5	7	10	10	5	5	0	0	0
0	0	0	0	0	0	10	0	69	0	0	0
70	0	0	1	0	2	0	0	90	0	0	0
80	0	0	0	0	0	0	0	100	0	0	0
20	40	0	0	0	0	40	0	0	0	0	0
0	0	10	80	80	10	0	30	5	10	0	0
0	60	0	80	80	0	0	0	0	0	60	0
0	60	10	10	10	0	2	1	2	5	60	50
70		70	80	0	80	0	0	70	80	0	80
80	0	80	80	0	80	0	0	80	80		80

n个“边”通过卷积可以得到n个特征图。n个特征图就是原图的另一种表达形式。


**思考：1个“边”的特征分布
图能表示图片的特征分布吗？**

多核卷积



使用不同的卷积核（即“边”）可以得到不同的特征图。
不同的特征图代表了不同特征（“边”）在原图中的分布情况。

特征图通道



n 个卷积核卷积之后可以得到 n 个特征图，也被称为 n 个通道的特征图。

使用“通道”代替图片与特征图：1个通道卷积生成3个通道。


多核卷积实例



一个手写数字“2”，使用20个卷积核卷积后的特征图。

**思考：特征图保留了原图的那些信息？
特征图与原图的关系是什么？**


特征图与原图的关系




卷积核保留了原图的局部特征；特征图保留了局部特征的强弱和位置信息。

卷积核与特征图可以看做原图的另一种表达形式。


特征图与原图的大小关系



原图 6*6



卷积核 2*2



特征图 5*5

原图的大小大于特征图的大小

小练习

1. 对10px*10px的图片使用3px*3px的卷积核做卷积得到的特征图大小是多少?

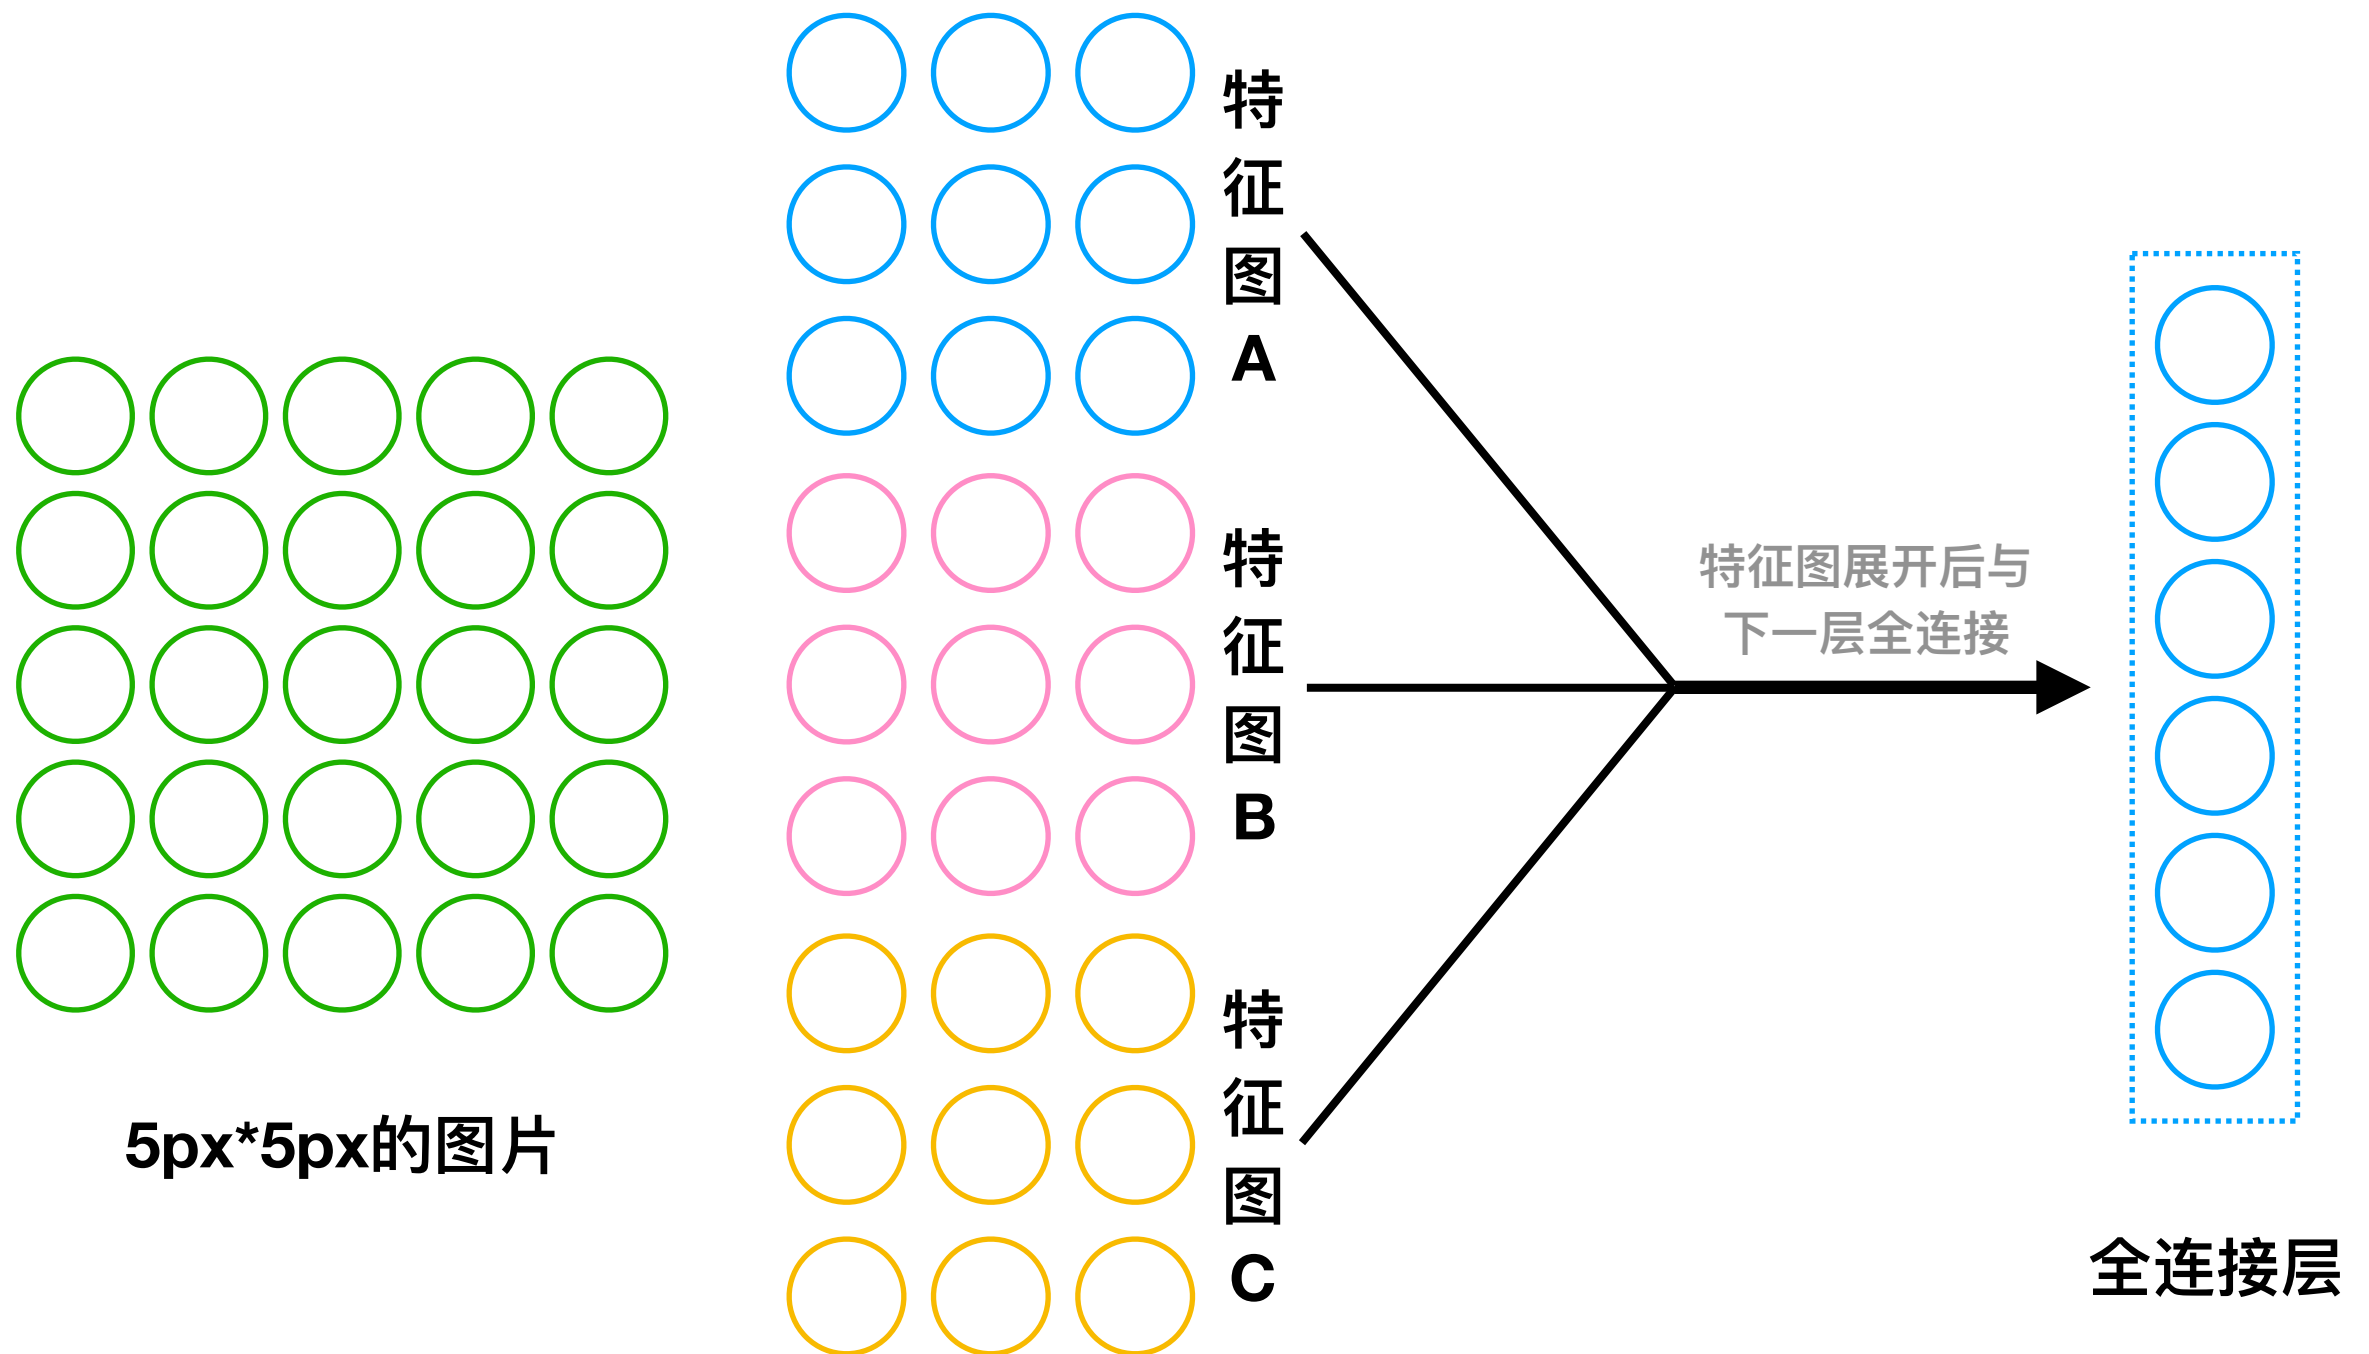
2. 对10px*10px的图片使用2px*3px的卷积核做卷积得到的特征图大小是多少?

思考：卷积的本质是什么？

特征提取

思考：可否使用特征图代替原图输入到神经网络？这样做有什么问题？

特征图作为输入





3次卷积得到的特征图

特征图直接作为输入的优缺点

- 保留了局部特征之间的关系。
- 特征图展开破坏了高维的位置信息。
- 直接使用特征图参数规模较大。

特征图下采样——池化



滑动窗大小?

滑动步幅大小?

Convolved
feature


Pooled
feature

最大池化：取一个区域的最大值。

平均池化：取一个区域的平均值。

思考：池化时，滑动窗的滑动步幅一定是滑动窗的大小吗？

特征图下采样——池化



Convolved
feature


Pooled
feature

在允许损失少量信息的情况下，对特征图进行下采样。池化使得图像获得了一定的平移不变性。


小练习

1. 对6*6的特征图使用3px*3px的滑动窗做池化得到的新特征图大小是多少?
2. 对10px*10px的图片使用5个3*3的卷积核做卷积得到的特征图，再以4*4的滑动窗做池化，得到了几张特征图？每张特征图的大小是多少？


卷积与池化组合



28*28像素的图像



3个由5*5卷积核得到的
特征图：3*24*24



3个6*6池化核池化后
的特征图：3*4*4

通过卷积与池化，可以有效的提取数据中的特征，并达到降低输入纬度的目的。

卷积神经网络:LeNet


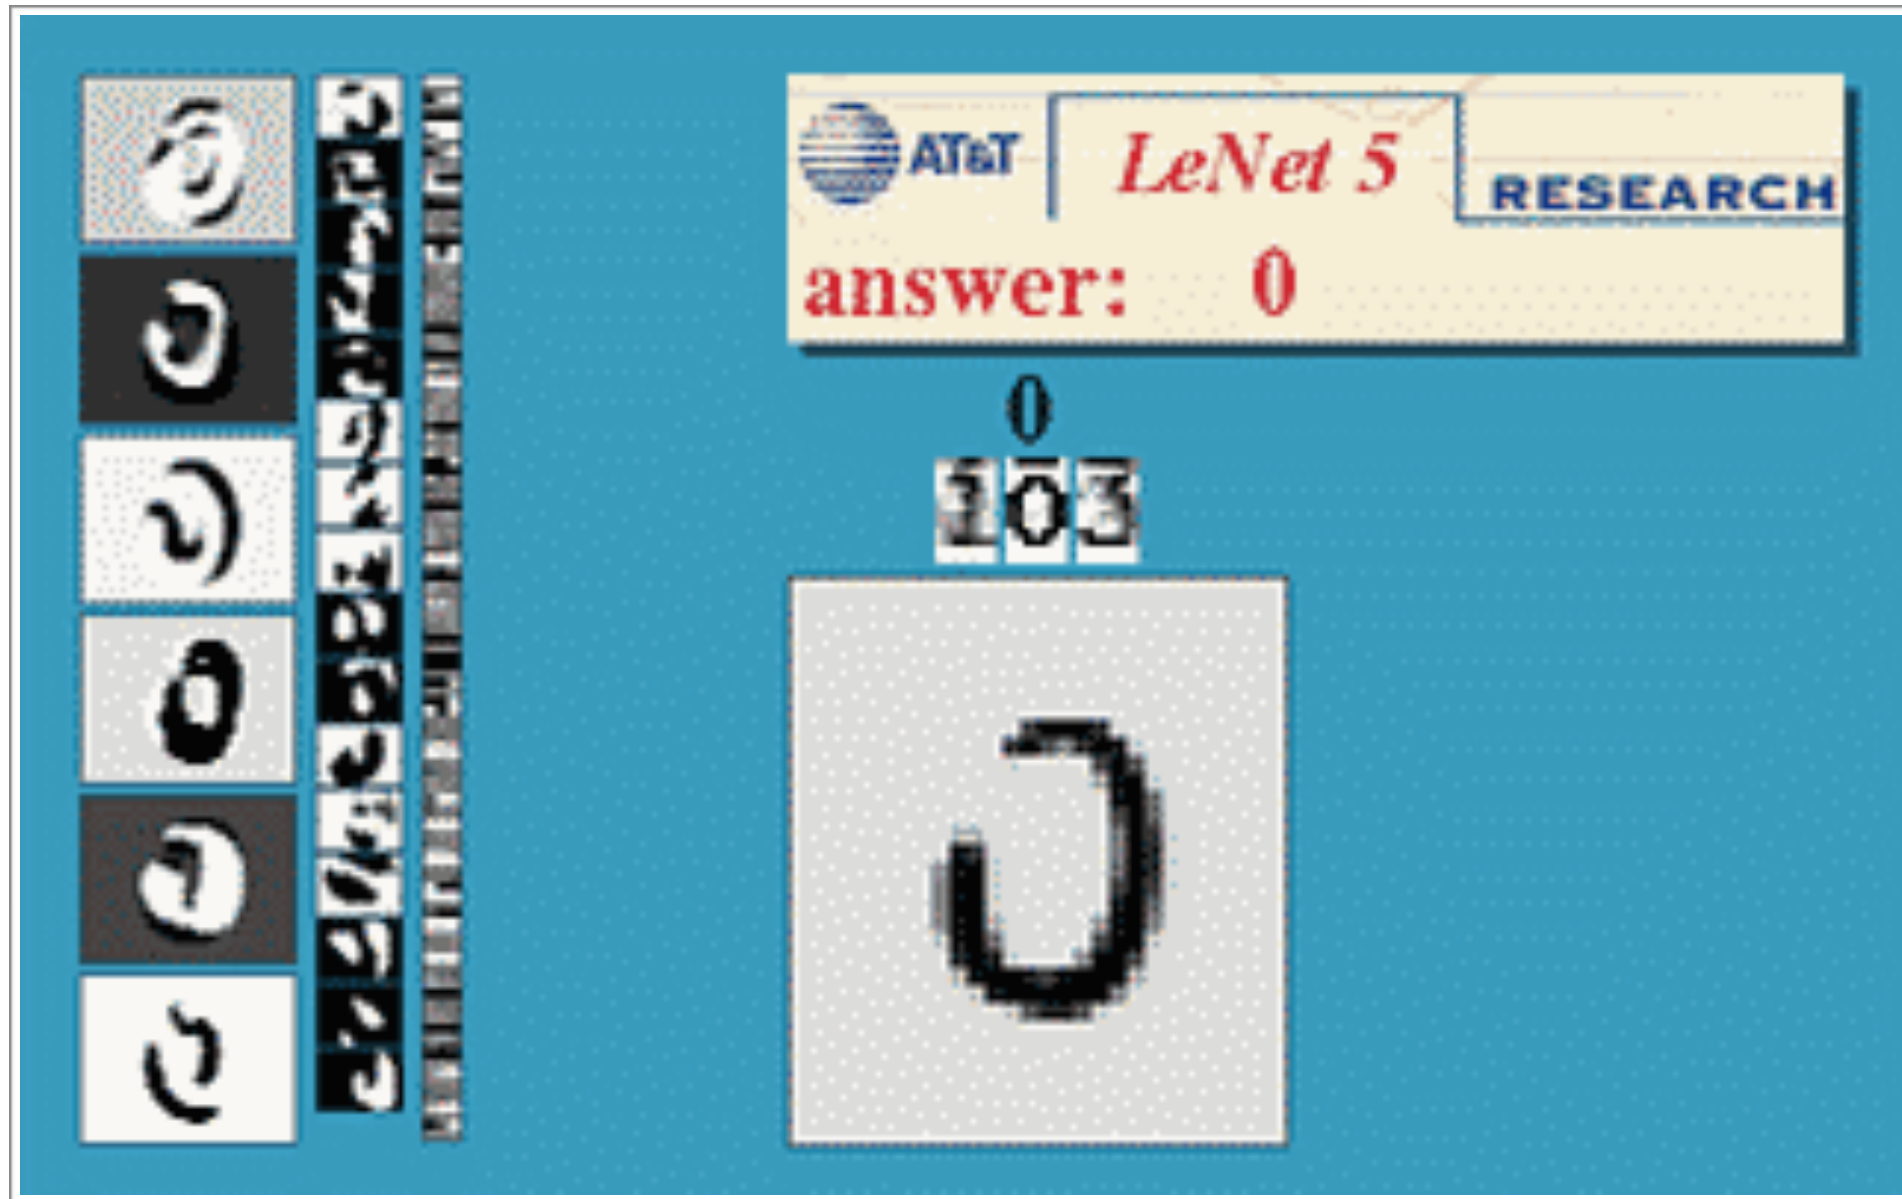


Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

论文: 《Gradient-Based Learning Appliea to Document Recognition》

卷积神经网络:LeNet



LeNet曾是美国各大银行等大机构最常用的识别手写体的算法。

小结

- 卷积神经网络包含有卷积层与池化层，可以降低数据维度，并有效提取特征。
- 卷积利用了数据的局部相关性，可以进行特征提取。
- 卷积得到的是卷积核所代表的特征在原图上的分布情况，即特征图。
- 一个卷积核可以得到一个特征图，通常我们需要多个卷积核才能完整提取图片特征。
- 通过下采样（池化）可以降低特征图的维度。

下节内容

- 多通道卷积。
- 卷积相关的计算。
- 卷积与池化的灵活应用。

THANKS