

深度学习

构造神经网络解决XOR问题



概览

1. 感知器与线性可分问题。
2. 激活函数的进化。
3. 线性不可分问题。
4. 构造逻辑运算神经元。
5. 构造神经网络解决XOR问题。
6. Python实现神经网络。

1. 感知器与线性可分问题

M-P模型

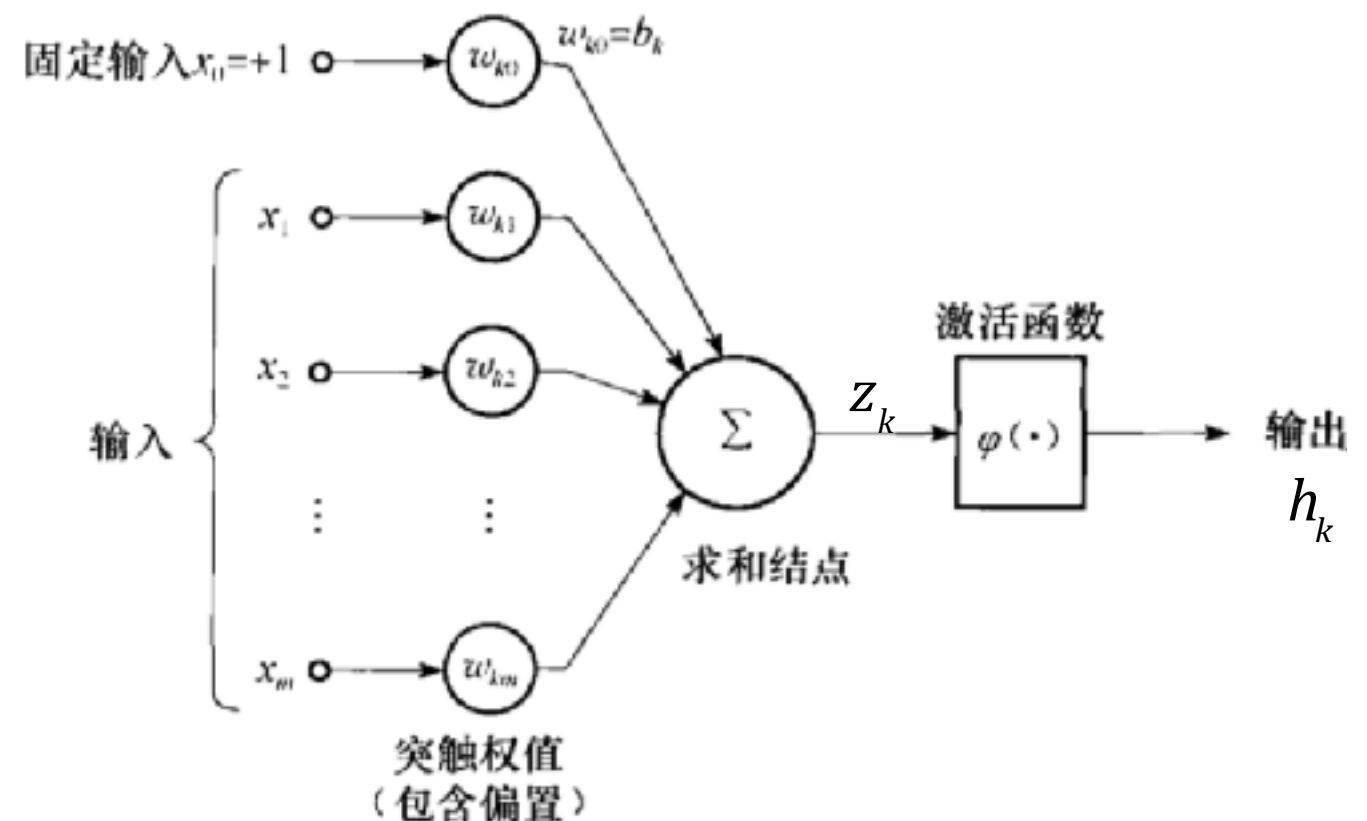
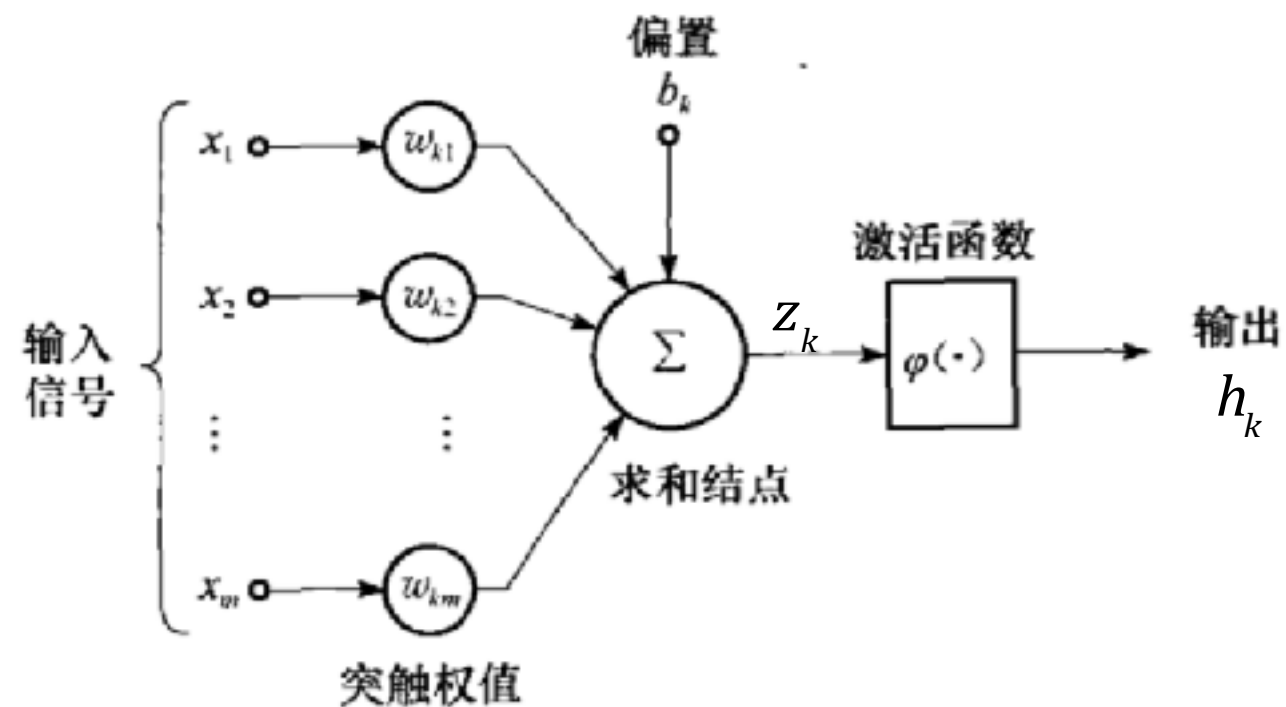
1943年，McCulloch与Pitts提出了M-P模型（McCulloch – Pitts' neuron model）。



阶跃函数

M-P模型

$$h = f\left(\left(\sum_i w_i x_i\right) - \theta\right) \text{ 等价于 } h = f\left(\left(\sum_i w_i x_i\right) + b\right) \text{ 等价于 } h = f\left(\sum_i w_i x_i\right)$$




M-P模型的特点

- 模拟了单个生物神经元的电流传导过程。
- 忽略整合作用。
- 忽略神经元不应期。
- 忽略了突触时延。
- 假定突触连接强度是固定的。

Rosenblatt感知器


1958年，Rosenblatt提出感知器作为第一个监督学习的ANN。Rosenblatt感知器建立在非线性神经元M-P模型之上。



特点：

1. 基于M-P模型构建，可用于二分类。
2. 可以对线性可分数据建模。
3. 可以进行监督训练。

Rosenblatt感知器的训练



$$h = f\left(\sum_i w_i x_i\right)$$

目标：找到一个权值向量 W 使得：

$W^T X > 0$ 表示一类数据

$W^T X \leq 0$ 表示另一类数据

注意：默认的所有的向量均为列向量

Rosenblatt感知器的训练

变量和参数:

$\mathbf{x}(n)$ = $m+1$ 维输入向量

$$= [+1, x_1(n), x_2(n), \dots, x_m(n)]^T$$

$\mathbf{w}(n)$ = $m+1$ 维权值向量

$$= [b, w_1(n), w_2(n), \dots, w_m(n)]^T$$

b = 偏置

$h(n)$ = 实际响应(量化的)

$y(n)$ = 期望响应

η = 学习率参数, 一个比 1 小的正常数

1. 初始化。设 $\mathbf{w}(0)=\mathbf{0}$ 。对时间步 $n=1, 2, \dots$ 执行下列计算。
2. 激活。在时间步 n , 通过提供连续值输入向量 $\mathbf{x}(n)$ 和期望响应 $y(n)$ 来激活感知器。
3. 计算实际响应。计算感知器的实际响应:

$$h(n) = \text{sgn}[\mathbf{w}^T(n)\mathbf{x}(n)]$$

这里 $\text{sgn}(\cdot)$ 是符号函数。

4. 权值向量的自适应。更新感知器的权值向量:

$$\mathbf{w}(n+1) = \mathbf{w}(n) + \eta[y(n) - h(n)]\mathbf{x}(n)$$

这里


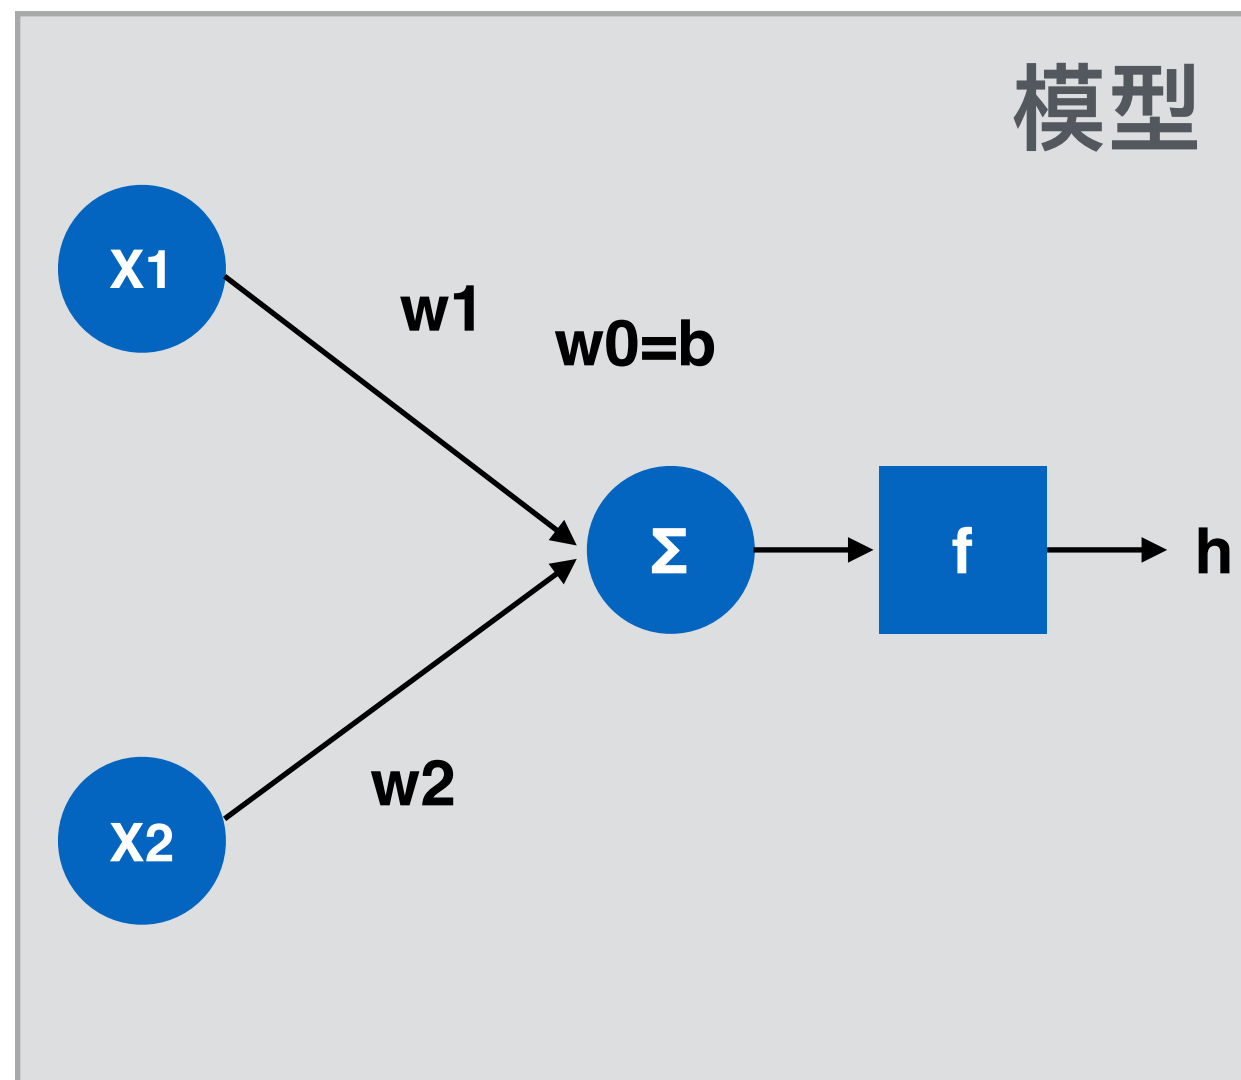
$$y(n) = \begin{cases} +1 & \text{若 } \mathbf{x}(n) \text{ 属于类 } \mathcal{C}_1 \\ -1 & \text{若 } \mathbf{x}(n) \text{ 属于类 } \mathcal{C}_2 \end{cases}$$

5. 继续。时间步 n 增加 1, 返回第 2 步。

感知器的训练实例

以包含两个输入的神经元为例：

a、b、d、e训练集
c、f测试集



感知器的训练实例


1. 初始化。

模型: $h = \text{sgn}(z) = \text{sgn}(w_0 + x_1 w_1 + x_2 w_2)$

参数初始化: $w_0 = w_1 = w_2 = 0$

学习率: $lr = 1$

$$h = \text{sgn}(0 + 0 * x_1 + 0 * x_2)$$



感知器的训练实例

2. 激活。

随机选择一个样本，使用模型处理，得到输出值。

此处选择点“a”，有：

$$\begin{aligned} Z &= w_0 + x_1 w_1 + x_2 w_2 \\ &= 0 + 1 * 0 + 1 * 0 \\ &= 0 \end{aligned}$$

感知器的训练实例

3. 计算响应（输出）。

输出： $h = \text{sgn}(z) = 0$

$$\text{sgn}(x) = \begin{cases} 1 & x > 0; \\ 0 & x \leq 0. \end{cases}$$

感知器的训练实例

4. 更新权值。

标记： 正类 $y = 1$

输出： $h = \text{sgn}(z) = 0$

更新： $w = w + lr(y - h)x \rightarrow$

$$\begin{aligned}w_0 &= 0 + 1 = 1 \\w_1 &= 0 + 1 = 1 \\w_2 &= 0 + 1 = 1\end{aligned}$$


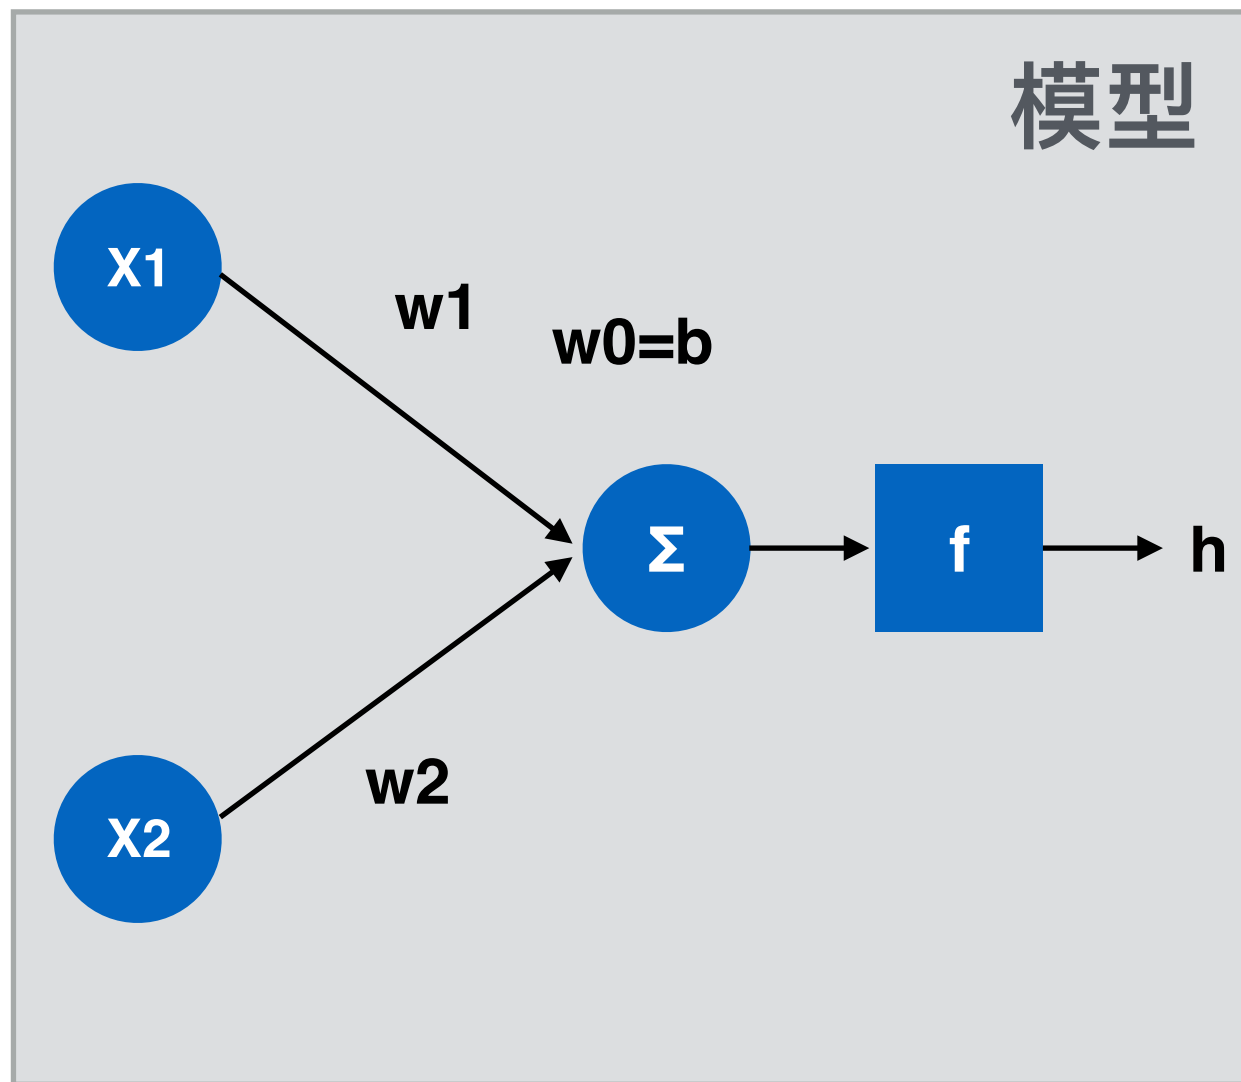
$$h = \text{sgn}(1 + 1 * x_1 + 1 * x_2)$$

感知器的训练实例

5. 重复2-4步骤。

分别带入b、d、e点进行训练。也可以重复使用训练集，直到算法收敛。

感知器的训练实例



分界线不止一条

Rosenblatt感知器

感知器是用于线性可分模式分类的最简单的神经网络模型。它由一个可以连接权重的神经元组成。


Rosenblatt证明了“**感知器收敛定理**”，即训练集线性可分时，感知器算法收敛。通过扩展感知器的输出层神经元数量其可以完成多分类任务。

实现：感知机


2. 激活函数的进化

激活函数分类

- 硬限幅器




- 软限幅器



logistic激活函数

$$y = \frac{1}{1+e^{-x}}$$



优点：

定义域为 \mathbb{R} ，值域为 $(0,1)$ 。
可以用来做二分类。
类似于生物神经元。


缺点：

计算量比较大。
求导涉及除法。
会导致梯度消失。

logistic神经元可以模拟逻辑回归。


常见神经元的激活函数

- 阶梯函数
- 线性函数
- 饱和线性函数
- 对数S形函数
- 强制非负校正函数
-



优秀的激活函数可以使神经网络更好的工作。设置线性激活函数或者不设置激活函数，会导致输出永远是输入的线性组合。

Identity



$$f(x) = x$$


Binary step



$$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ 1 & \text{for } x \geq 0 \end{cases}$$

早期感知机激活函数

Logistic (a.k.a.
Soft step)



$$f(x) = \frac{1}{1 + e^{-x}}$$


早期常用激活函数

TanH




$$f(x) = \tanh(x) = \frac{2}{1 + e^{-2x}} - 1$$

ArcTan



$$f(x) = \tan^{-1}(x)$$


Softsign [7][8]



$$f(x) = \frac{x}{1 + |x|}$$

注意：一个神经网络中不一定只有一种激活函数。


Rectified linear
unit (ReLU)^[9]



$$f(x) = \begin{cases} 0 & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$$

现在常用激活函数


Leaky rectified
linear unit
(Leaky
ReLU)^[10]




$$f(x) = \begin{cases} 0.01x & \text{for } x < 0 \\ x & \text{for } x \geq 0 \end{cases}$$

3. 线性不可分问题

线性不可分



线性可分



线性不可分


请问： 以下数据集是否线性可分？

- a. 手写数字数据集MNIST
- b. 近五年中国房屋价格与面积的数据集
- c. 用于做人脸验证的数据集YouTube Video Faces

大部分的数据是线性不可分的，线性不可分的数据需要非线性模型进行拟合。

线性不可分与异或 (XOR)

西瓜好坏与西瓜大小、西瓜颜色深浅的关系可由四个样本表示如下：



用 $x_1=1$ 表示 x_1 的输入为真
用 $x_1=0$ 表示 x_1 的输入为假
用 $x_2=1$ 表示 x_2 的输入为真
用 $x_2=0$ 表示 x_2 的输入为假

XOR输入不同输出1

XOR即异或门，也是一个半加器 在图像上表现出线性不可分。

4. 构造模拟逻辑运算的神经元

前提


1. 使用单个神经元。
2. 使用logistic神经元。

构造AND逻辑运算单元


$$x_1, x_2 \in \{0, 1\}$$

$$y = x_1 \text{ AND } x_2$$

x_1	x_2	$h_{\Theta}(x)$
0	0	
0	1	
1	0	
1	1	




构造逻辑运算单元OR



x_1	x_2	$h_{\Theta}(x)$
0	0	
0	1	
1	0	
1	1	

构造逻辑运算单元NOT



x_1	$h_{\Theta}(x)$
0	
1	

思考：使用感知器能否构造基础逻辑运算？

5. 构造神经网络解决XOR问题


使用基础逻辑运算单元可以构建XOR单元。

$$A \text{ xor } B = (A \text{ and } (\text{not } B)) \text{ or } ((\text{not } A) \text{ and } B)$$


x_1	x_2	$h_{\Theta}(x)$
0	0	
0	1	
1	0	
1	1	

输入不同输出1


利用逻辑神经元构建XOR神经网络



最简单的XOR神经网络




结构图



信号流图


注意：此处使用的是感知器神经元。

构造神经网络



图中每一个圆圈代表一个神经元(unit)。多个神经（一竖行）元组成一个层（layer）。层与层的神经元之间全连接。第一层我们称之为输入层，最后一层为输出层，其余为隐藏层。神经网络是一个有向无环图。

如何参数设置



实际中，我们并不手动设计神经网络的结构和参数。而是使用**反向传播算法**自动求参数。

playground演示

6. Python实现神经网络

小节

- 感知器的形态与性质。
- 感知器的训练过程。
- 常用激活函数logistic函数、双曲正切函数、修正线性单元、softmax函数。
- Sigmoid函数的值域决定了其可以做二分类。
- 线性不可分是常见的情形，需要使用非线性模型拟合。
- 神经网络构造逻辑单元并解决XOR问题。

THANKS